ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

ΣΧΟΛΗ ΗΜ&ΜΥ

Προηγμένα Θέματα
Αρχιτεκτονικής Υπολογιστών

4η Άσκηση
Ακ. έτος 2011-2012

Γρηγόρης Λύρας Α.Μ.: 03109687

21 Ιουλίου 2012

Μέρος Α΄

1 Εισαγωγή

Στην άσκηση αυτή προσομοιώνουμε με χρήση του Simics τον πολλαπλασιασμό δύο τετραγωνικών πινάκων Α και Β χρησιμοποιώντας διάφορες τεχνικές βελτιστοποίησης.

2 Περιβάλλον Προσομοίωσης

Για το εκτελέσιμο χρησιμοποιούμε γλώσσα C και gcc, χωρίς optimization flags.

```
target$ gcc -O1 -o executable partA.c
```

2.1 Προσομοίωση

Ο κώδικας που μας δόθηκε ήταν ο ακόλουθος:

```c
/* -.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.
 * File Name : partA.c
 * Creation Date : 16-07-2012
 * Last Modified : Mon 16 Jul 2012 01:46:39 PM EEST
 * Created By : Greg Liras <gregliras@gmail.com>
 _.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-.*/

#include <stdio.h>
#include <stdlib.h>
#define __MAGIC_CASSERT(p) do {                         \
    typedef int __check_magic_argument[(p) ? 1 : -1];   \
} while (0)

#define MAGIC(n) do {                       \
    __MAGIC_CASSERT(!(n));                  \
    __asm__ __volatile__ ("xchg %bx,%bx");  \
} while (0)

#define MAGIC_BREAKPOINT MAGIC(0)



inline int min(int a, int b)
{
    if(a<=b)return a;
    else return b;
}
void init_matrix(float **mat, int n)
{
    unsigned int i,j;
    for(i=0; i<n; i++)
        for(j=0; j<n; j++)
            mat[i][j] = (float)(i+j);
}
int main(int argc, char **argv)
{
    float **A,**B,**C;
    int i,j,k,N;
    N=atoi(argv[1]);
    A=(float**)malloc(N*sizeof(float*));

    for(i=0; i<N; i++)
        A[i]=(float*)malloc(N*sizeof(float));

    B=(float**)malloc(N*sizeof(float*));

    for(i=0; i<N; i++)
        B[i]=(float*)malloc(N*sizeof(float));
```

```
49
50      C=(float**)malloc(N*sizeof(float*));
51
52      for(i=0; i<N; i++)
53          C[i]=(float*)malloc(N*sizeof(float));
54
55      fprintf(stderr, "Initializing matrices...\n");
56      init_matrix(A, N);
57      init_matrix(B, N);
58      init_matrix(C, N);
59      MAGIC_BREAKPOINT;
60      for(i=0; i<N; i++) {
61          for(j=0; j<N; j++)
62              for(k=0; k<N; k++)
63                  C[i][j] += A[i][k]*B[k][j];
64      }
65      MAGIC_BREAKPOINT;
66      return 0;
67  }
```

2.2 Ιεραρχία μνήμης και μοντέλο απόδοσης

Χρησιμοποιήσαμε την ιεραρχία μνήμης όπως μας δίνεται στο Παράρτημα. Αυτή έχει δύο επίπεδα κρυφής μνήμης L1 (2 way set associative 64 bytes $\times$ 512 lines write-through LRU policy) και L2 (4 way set associative 128 bytes $\times$ 1024 lines write-back LRU policy).

	assoc	line size	lines	size
L1 instruction cache	2	64	512	32768 = 32 KB
L1 data cache	2	64	512	32768 = 32 KB
L2 cache	4	128	1024	131072 = 128 KB

Πίνακας 1: Cache Hierarchy

Στο μοντέλο που προσομοιώνουμε οι κύκλοι υπολογίζονται χωρίς penalty από το Simics. Για να υπολογίσουμε τους κύκλους θεωρούμε πως πρόσβαση στην L1 cache γίνεται σε 1 κύκλο, στην L2 σε 20 κύκλους και στη μνήμη σε 300 κύκλους οπότε έχουμε τον τύπο:

$$Cycles = Inst + L1_{Accesses} * L1_{Time} + L2_{Accesses} * L2_{Time} + Mem_{Accesses} * Mem_{Time} \quad (1)$$

2.3 Αρχική έκδοση

Προσομοιώσαμε τον αρχικό κώδικα, όπως φαίνεται παραπάνω και πήραμε τα ακόλουθα αποτελέσματα.

Cycles	1523400216
L1 miss ratio	0.029
L2 miss ratio	0.015

Πίνακας 2: Μετρικές πρώτης εκτέλεσης

3 Τεχνικές Βελτιστοποίησης

3.1 Loop Interchange

Για την προσομοίωση κάναμε 6 εκτελέσεις για κάθε διάταξη των i,j,k όπως φαίνεται στον πίνακα 3.

Σειρά προσομοίωσης	Διάταξη
1	i,j,k
2	i,k,j
3	j,i,k
4	j,k,i
5	k,i,j
6	k,j,i

Πίνακας 3: Δυνατές Διατάξεις

Τα αποτελέσματα φαίνονται στα ακόλουθα σχήματα.

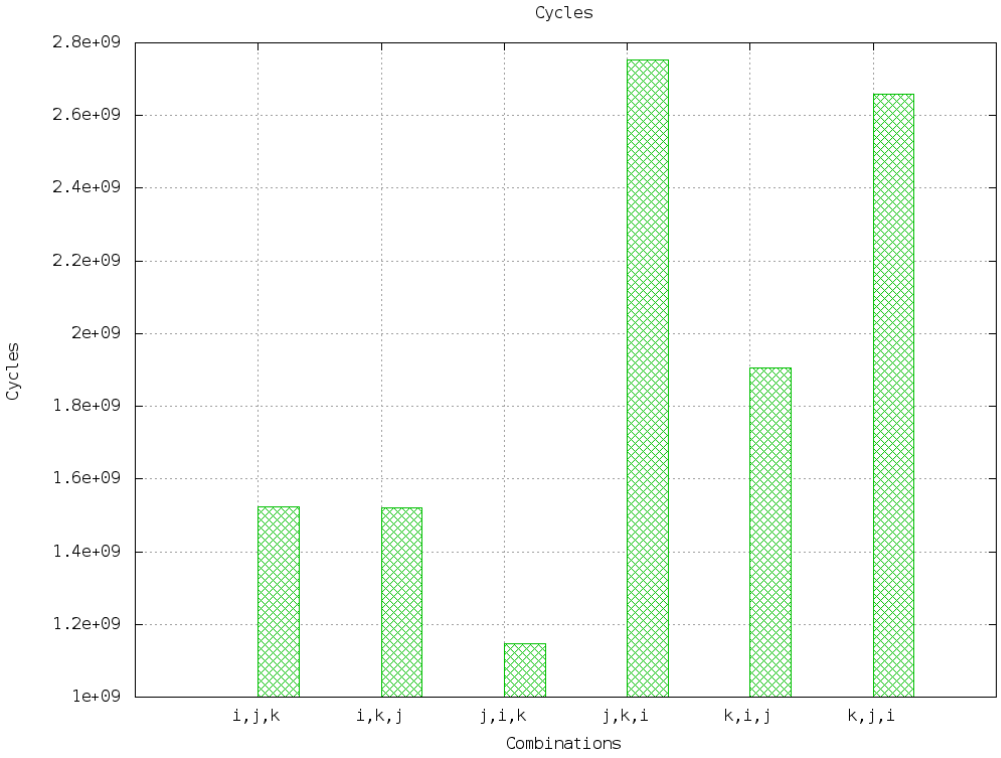

Σχήμα 1: Cycles

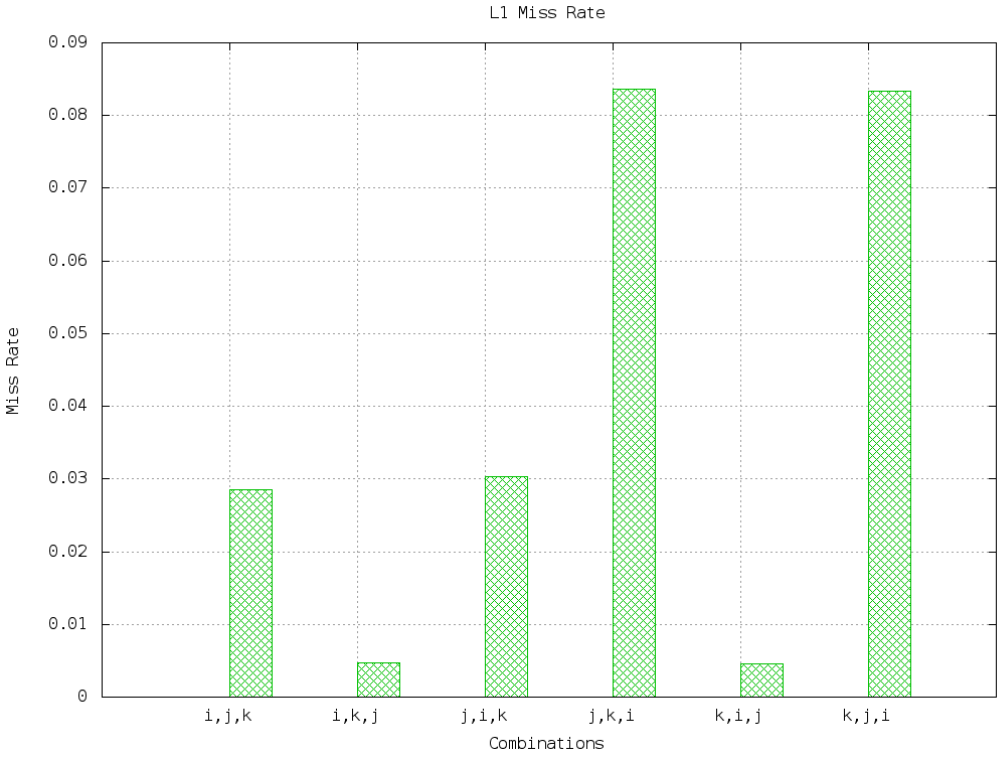

Σχήμα 2: L1 Miss Rate

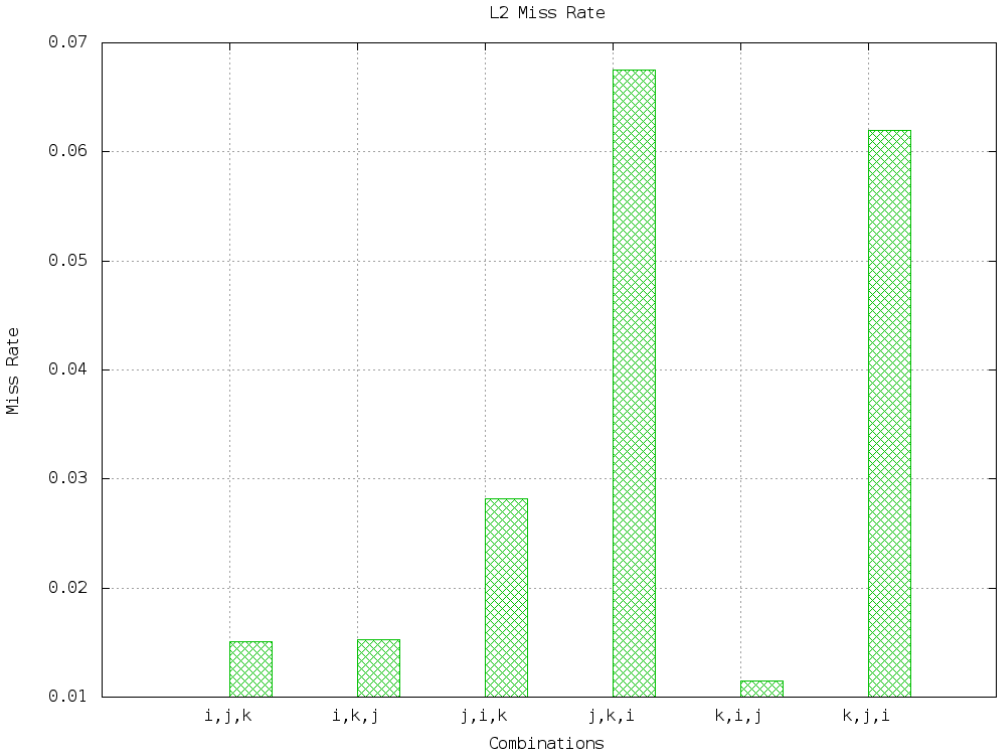

Σχήμα 3: L2 Miss Rate

Cycles	L1 Miss rate	L2 Miss rate	Speedup
1523400216	0.0285	0.0150	1.0
1519770751	0.0046	0.0152	1.00
1145990549	0.0303	0.0281	1.32
2752007165	0.0835	0.0675	0.55
1905041698	0.0045	0.0115	0.79
2659818958	0.0833	0.0619	0.57

Πίνακας 4: Μετρικές όλων των εκτελέσεων

Ανάλογα με τη διάταξη των loops οι πίνακες διασχίζονται κατά γραμμές και κατά στήλες σε διάφορους συνδυασμούς. Μεγαλύτερο speedup παρατηρούμε στη διάταξη j,i,k.

3.2 Cache Blocking

Η L1 cache έχει μέγεθος 32KB, και line size 64 bytes. Κάνουμε πράξεις μεταξύ αριθμών κινητής υποδιαστολής σε 32bit σύστημα συνεπώς κάθε ένας έχει μέγεθος 4bytes. Κάθε cache line χωράει 16 αριθμούς συνεπώς για να εκμεταλλευτούμε καλύτερα την τοπικότητα των αναφορών θα εκτελούμε κάθε loop σε ομάδες. Έτσι θα χρησιμοποιούμε δεδομένα που έχουν ήδη έρθει στην cache.

```
/* -.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.-.
 * File Name : partA.c
 * Creation Date : 16-07-2012
 * Last Modified : Fri 20 Jul 2012 05:37:36 PM EEST
 * Created By : Greg Liras <gregliras@gmail.com>
 _.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-._.-.*/

#include <stdio.h>
#include <stdlib.h>
#define __MAGIC_CASSERT(p) do {                         \
    typedef int __check_magic_argument[(p) ? 1 : -1];   \
} while (0)

#define MAGIC(n) do {                       \
    __MAGIC_CASSERT(!(n));                  \
    __asm__ __volatile__ ("xchg %bx,%bx");  \
} while (0)

#define MAGIC_BREAKPOINT MAGIC(0)



inline int min(int a, int b)
{
    if(a<=b)return a;
    else return b;
}
void init_matrix(float **mat, int n)
{
    unsigned int i,j;
    for(i=0; i<n; i++)
        for(j=0; j<n; j++)
            mat[i][j] = (float)(i+j);
}
int main(int argc, char **argv)
{
    float **A,**B,**C;
    int i,j,k,N;
    int starti,stopi;
    int startj,stopj;
    int startk,stopk;
    int BS = atoi(argv[2]);
    N=atoi(argv[1]);
    A=(float**)malloc(N*sizeof(float*));

    for(i=0; i<N; i++)
        A[i]=(float*)malloc(N*sizeof(float));

    B=(float**)malloc(N*sizeof(float*));

    for(i=0; i<N; i++)
        B[i]=(float*)malloc(N*sizeof(float));

    C=(float**)malloc(N*sizeof(float*));

    for(i=0; i<N; i++)
        C[i]=(float*)malloc(N*sizeof(float));

    fprintf(stderr, "Initializing matrices...\n");
    init_matrix(A, N);
    init_matrix(B, N);
    init_matrix(C, N);
    MAGIC_BREAKPOINT;
    for(startj=0; startj<N; startj+=BS) {
        stopj = startj + BS;
```

```
66          stopj = stopj <= N ? stopj : N;
67          for(starti=0; starti<N; starti+=BS) {
68              stopi = starti + BS;
69              stopi = stopi <= N ? stopi : N;
70              for(startk=0; startk<N; startk+=BS) {
71                  stopk = startk + BS;
72                  stopk = stopk <= N ? stopk : N;
73                  for(j=start; j<stop; j++)
74                      for(i=start; i<stop; i++)
75                          for(k=start; k<stop; k++)
76                              C[i][j] += A[i][k]*B[k][j];
77              }
78          }
79      }
80      MAGIC_BREAKPOINT;
81      return 0;
82  }
```

Cycles	L1 Miss rate	L2 Miss rate	Speedup
1229008147	0.00200081611811	0.00436512977739	1.0
1116424502	0.00222865322992	0.00355591913984	1.10084304384
1090971021	0.00276906476251	0.00363915609977	1.12652684933
1077600084	0.00364079131771	0.00337975797327	1.14050487305
1074879790	0.00406211929743	0.00347469774194	1.14339125029
1077724197	0.00460946323771	0.00443471065927	1.14037353009
1076847331	0.0050673609159	0.00464953114037	1.14130212484
1092092535	0.00608081927452	0.00734009216841	1.12536997334
1080181105	0.00554504027806	0.00586511858615	1.13777971241
1082269217	0.00561610467505	0.00616771173416	1.1355844994
1085119465	0.00598425140451	0.00724845710677	1.13260169653
1089671800	0.00604447720433	0.00797237050637	1.12787001279
1093319686	0.0062805931738	0.00837639698304	1.12410684884
1106283098	0.00649260144475	0.0104062454345	1.11093457834
1134938000	0.00634545344483	0.0155069937752	1.08288571446
1150045093	0.00692636946452	0.0186948544829	1.06866083294

Πίνακας 5: Διαφορά των εκτελέσεων

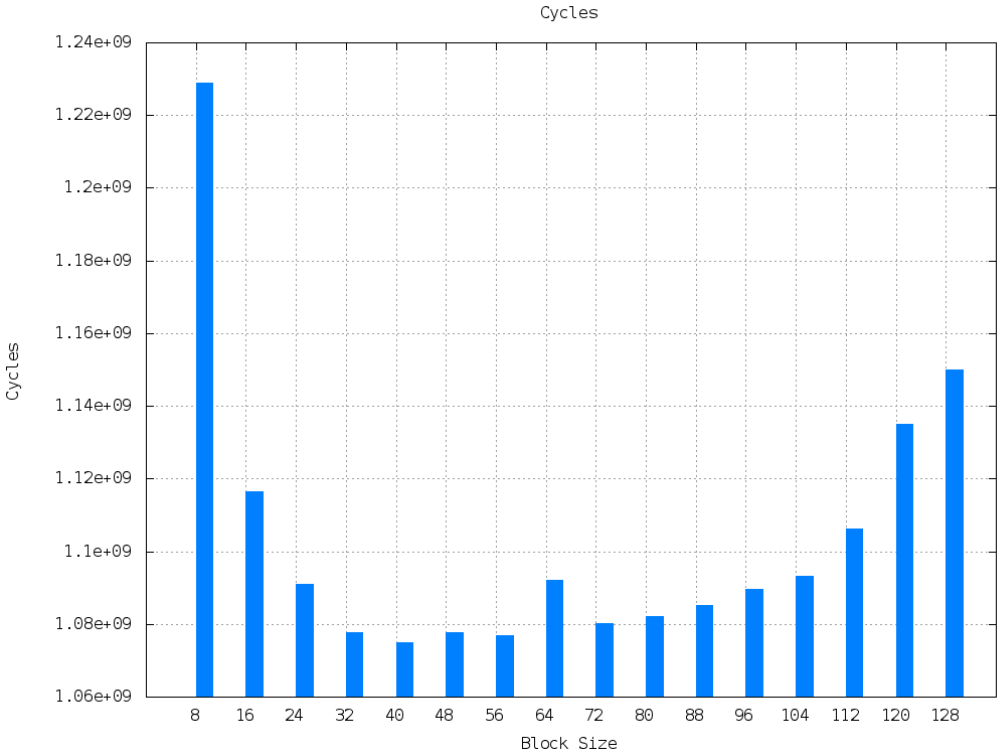

Σχήμα 4: Cycles

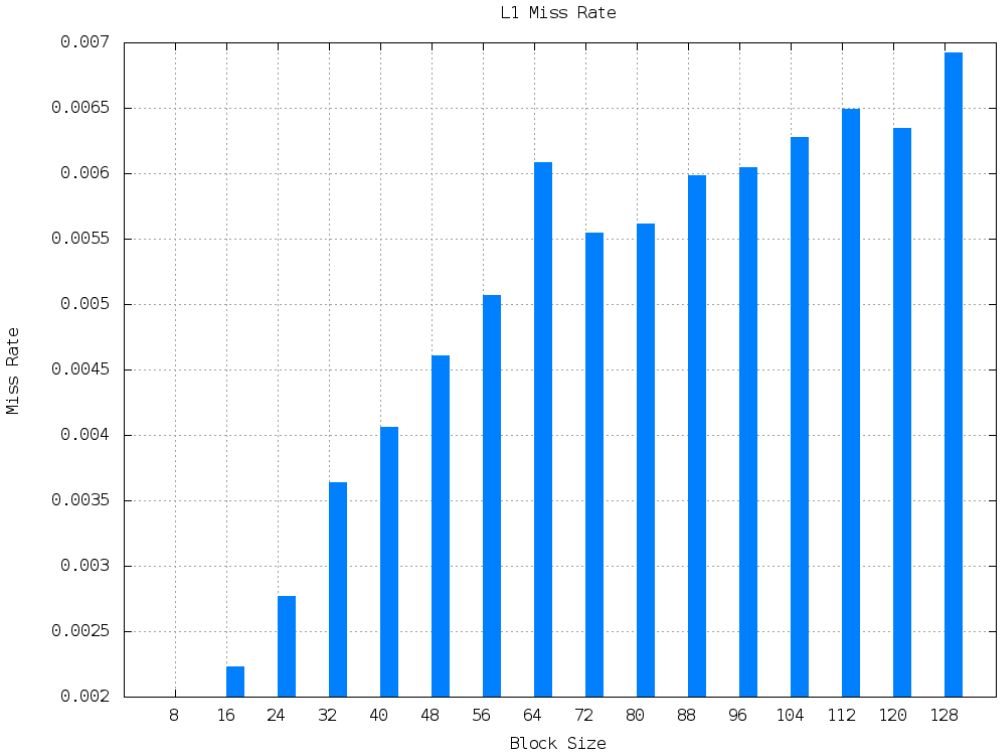

Σχήμα 5: L1 Miss Rate

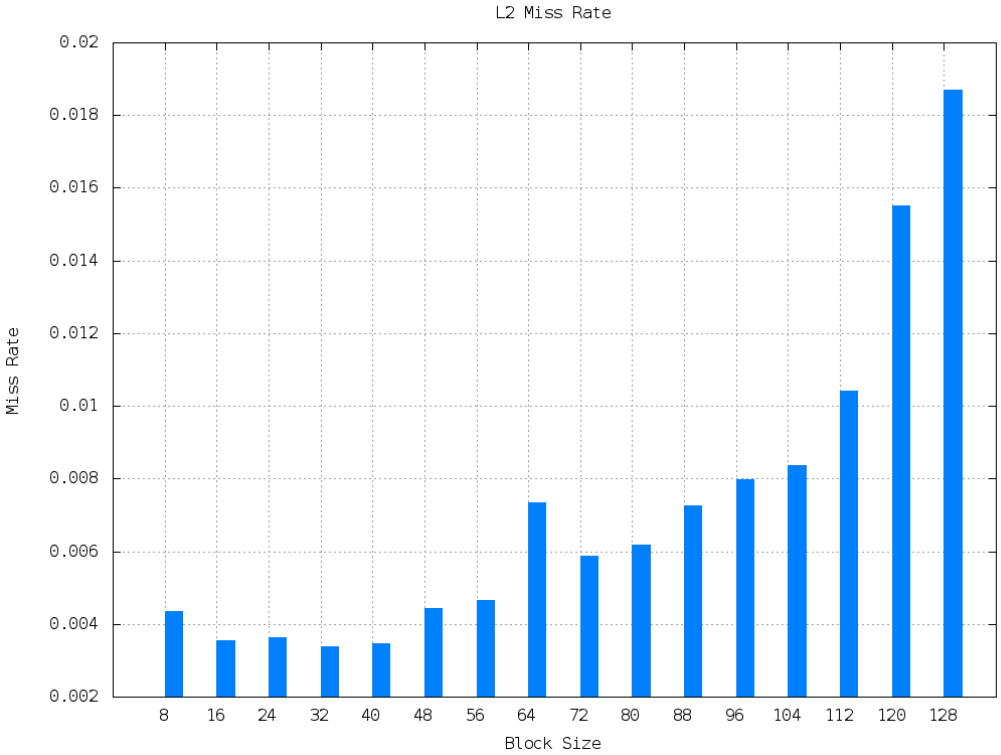

Σχήμα 6: L2 Miss Rate

Η απλοική εκτέλεση διαρκεί 1523400216 cycles. Η βέλτιστη cache blocked 1074879790. Το speedup που υπολογίζουμε από αυτή τη διαφορά είναι 1.41.

Παρατηρούμε πως η μεταβολή του block size στο πρόγραμμά μας, αν και αυξάνει το πλήθος των εντολών του προγράμματος, αυξάνει την ταχύτητά του καθώς εκμεταλλεύεται καλύτερο την τοπικότητα των αναφορών. Ωστόσο για ακραίες τιμές η επιτάχυνση δεν είναι πολύ σημαντική. Είναι μια τεχνική που μπορεί να εφαρμοστεί ταυτόχρονα με την αναδιάρθρωση των βρόχων αρκεί το pattern να μην είναι τυχαίο αλλά η πρόσβαση στα δεδομένα να μπορεί να μετασχηματιστεί σε αντίστοιχη μορφή.

Μέρος Β΄

1 Πρωτόκολλο MESI

2 Memory Consistency